



BIG DATA

Base de Datos II



DEFEDERICO BENJAMIN - TANANTA CARLOS - TIZIANO TONELLO -
BABBICOLA FRANCO

U.T.N MDP - 2026

Profesor: Adrian Aroca

Contents

¿Qué es Big Data?	2
Historia	4
Características de Big Data	6
Las 5 Vs de Big Data	8
Estructura de datos	8
Datos Estructurados.....	9
Datos Semiestructurados.....	9
Datos No Estructurados	9
Gestión de Datos	11
Recopilación	12
Almacenamiento.....	12
Procesamiento	13
Análisis	14
Tecnologías Relacionadas.....	15
Hadoop	15
Apache Spark.....	16
NoSQL.....	17
Implementaciones.....	19
Caso Practico: Mercado Libre	21
Características	22
Aplicaciones	22
Espacios de Información Nacional	23
Portal Nacional de Transparencia.....	24
Observatorio Nacional de Big Data	24
Conclusión	24
Tabla Resumen	25
Bibliografía	27

¿Qué es Big Data?

Big Data se refiere a conjuntos de datos extremadamente grandes y complejos (estructurados, semiestructurados y no estructurados) que superan las capacidades de las herramientas tradicionales de gestión y análisis de datos. No solo se trata del tamaño (volumen), sino de la velocidad de generación, la variedad de formatos y la necesidad de extraer valor en tiempo útil. En otras palabras, Big data es un paradigma de trabajo, enfocado a resolver problemas orientados a los datos. Se analizan datos masivamente para entender o predecir situaciones.

Cada día se crean cantidades masivas de información provenientes de redes sociales, dispositivos IoT, transacciones comerciales, sensores y otras fuentes. Este fenómeno ha dado lugar al concepto de Big Data.

La ciencia de datos y, más específicamente, el análisis de Big data ayudan a las organizaciones a dar sentido a los grandes y diversos conjuntos de datos. Estos campos utilizan herramientas avanzadas (como el machine learning) para descubrir patrones, extraer conocimientos y predecir resultados.

Historia

El concepto Big Data como lo conocemos fue tomando lugar y relevancia a finales de la década de los 90 y principio de los 2000, debido a que las empresas cada vez generaban cantidades masivas de datos todos los días, también por el gran avance y evolución que fue teniendo el internet y las tecnologías relacionadas con él.

Inicialmente las bases de datos tradicionales eran suficiente para el análisis, almacenamiento y procesamiento de datos e información de las empresas. Pero con la aparición de plataformas web como Google, Facebook o Amazon, las cantidades de datos que se producían cada día fueron en aumento. Debido a esto, las empresas comenzaron a necesitar de tecnologías capaces de analizar, recopilar y procesar estos conjuntos masivos de datos de una manera organizada.


Una de las empresas que realizó avances en la tecnología sobre datos fue Google, ya que en 2005 publicó investigaciones relacionadas con sistemas de procesamiento distribuido. Las cuales inspiraron a la creación de Hadoop, la cual es una de las herramientas fundamentales de Big Data. Y, más adelante surgieron nuevas tecnologías como Apache Spark, bases de datos NoSQL y plataformas de almacenamiento en la nube.

Y con tecnologías actuales, Big Data está estrechamente vinculado con la inteligencia artificial y el machine learning, los cuales permiten el desarrollo de uno de los cambios más importantes en la tecnología actual. El crecimiento del análisis predictivo, permitiendo anticipar comportamientos utilizando información previa. Esto les permite por ejemplo a empresas de comercio recomendar productos, a plataformas de streaming recomendar contenido personalizado y a que empresas financieras puedan detectar fraudes.

Con el tiempo, Big Data impulsó el crecimiento de las nuevas áreas tecnológicas: La inteligencia artificial, machine learning, Deep learning, internet de las cosas (IoT)

Ahora las organizaciones consideran a los datos como los recursos más valiosos, sacando productividad competitiva gracias al gran análisis que les permite esta herramienta. Muchas plataformas supieron sacarles ventaja a estos recursos, por ejemplo:

- **Netflix:** Junto con el análisis predictivo, esta plataforma analiza los contenidos que ve el usuario para luego recomendar series o películas de forma personalizada
- **Spotify:** De la misma manera que Netflix, usa algoritmos para generar listas de música, basadas en los gustos musicales del usuario
- **Google Maps:** Puede procesar información de millones de dispositivos para calcular el tráfico en tiempo real
- **Mercado libre:** A partir de compras, búsquedas, favoritos, recomienda productos a los usuarios
- **Uber:** Calcula rutas, tiempos de viaje, tarifas dinámicas que pueden aumentar automáticamente cuando crece la demanda
- **Mercado pago:** analiza millones de transacciones diarias. Recopilando y procesando información relacionada a pagos, ubicaciones, dispositivos y comportamientos financieros. Por lo que puede detectar fraudes, junto con mejoras de seguridad, analizando riesgos. También ofreciendo promociones y servicios personalizados



Evolución histórica del Big Data desde 1996 hasta 2011, dividida en etapas. Muestra cómo internet y las tecnologías de datos fueron creciendo.

Características de Big Data

Big Data actualmente representa un término que se volvió muy fundamental para quienes necesitan manejar grandes volúmenes de información. Esto se evidencia gracias a los beneficios que surgieron luego de su implementación en los sistemas:

- Mejora la toma de decisiones precisas, ya que permite que el análisis de información sea real y actualizada, reduciendo errores.
- El público general se ve más satisfecho, ya que se les puede ofrecer contenido personalizado en distintas plataformas.
- Hay una mejor organización y eficiencia operativa, permitiendo la optimización de procesos, detectando fallos y haciendo más eficientes sus sistemas.
- Sistemas financieros utilizan Big data para identificar operaciones sospechosas.
- Permite anticipar acciones o comportamientos futuros mediante análisis predictivos.

A Big Data se le dio el apodo de “el nuevo petróleo” gracias a lo fundamental que se volvió para el crecimiento de las empresas.

A pesar de sus beneficios, este término comprende varios desafíos importantes:

- La conexión y el mantenimiento de datos se vuelven más complicados de manejar, ya que son sistemas que constantemente están recibiendo y enviando información.
- La escalabilidad del sistema debe ser constante ya que los datos van en crecimiento, por lo que se debe ampliar constantemente centros de almacenamiento y procesamientos, generando altos costos.
- Los diferentes tipos de datos pueden ser complejos al querer integrarlos entre si (datos estructurados, no estructurados y semiestructurados).
- Encontrar mano de obra profesional se vuelve una tarea complicada ya que se necesita gente que comprenda la gestión y análisis de datos.
- El masivo uso de datos personales puede generar problemas con la privacidad de los usuarios.
- La calidad de los datos puede verse afectada ya que, si alguno de ellos contiene errores de información o similar, los resultados que se obtendrán de estos también serán incorrectos.

Tradicionalmente, se han reconocido los modelos de Big data por tres características: variedad, volumen y velocidad, también conocidas como las "tres V". Sin embargo, han surgido dos V adicionales en los últimos años.

Las 5 Vs de Big Data

1. **Volumen:** Cantidades masivas de datos. Puede tratarse de datos de valor desconocido, como feeds de datos de X, flujos de clics de una página web o aplicación para móviles, o equipo con sensores. Para algunas organizaciones, esto puede suponer decenas de terabytes de datos. Para otras, incluso cientos de petabytes.
2. **Velocidad:** El ritmo al que los datos entran en un sistema. Los datos pueden llegar más rápido que nunca, desde actualizaciones de redes sociales en tiempo real hasta registros de transacciones bursátiles de alta frecuencia. Para abordar esto, las organizaciones utilizan herramientas como marcos de procesamiento de flujo y sistemas en memoria para capturar, analizar y actuar sobre los datos casi en tiempo real.
3. **Variedad:** Los distintos formatos que puede adoptar Big data puede incluir datos no estructurados como texto, imágenes y vídeos de forma libre. También puede incluir datos semiestructurados, como archivos JSON y XML, que tienen algunas propiedades organizativas, pero no un esquema estricto.
4. **Valor:** Los beneficios reales que las organizaciones pueden obtener de Big data. Estos beneficios incluyen todo, desde la optimización de las operaciones comerciales hasta la identificación de nuevas oportunidades de marketing.
5. **Veracidad:** La exactitud y fiabilidad de los datos. Debido a que Big data proviene de cantidades tan grandes y de diversas fuentes, puede contener ruido o errores, lo que puede conducir a una mala toma de decisiones.

Estructura de datos

En Big Data no existe una única estructura de datos. La información se clasifica en tres grandes estructuras según su nivel de organización y flexibilidad.

Datos Estructurados

Es el conjunto de datos que tiene un formato rígido, un esquema fijo y está organizada en tablas de filas y columnas.

- Características: Los datos se almacenan en tablas, tiene tipos de datos definidos (números, fechas, texto) y se consulta mediante SQL.
- Ejemplos:
 - Tablas de base de datos relacionales (MySQL, PostgreSQL).
 - Archivos de hojas de cálculo (Excel, CSV bien formateados).

Datos Semiestructurados

Estos no caben en una tabla típica de filas y columnas, pero contienen marcadores, etiquetas o jerarquías internas que separan los elementos y les dan orden.

- Características: Tienen esquemas flexibles (pueden cambiar de una fila a otra) y se procesan de forma nativa en base de datos NoSQL o herramientas como Apache Spark
- Ejemplos:
 - Archivos JSON (los que usa Spring Boot para comunicarse con el front end)
 - Archivos XML o HTML (páginas web).

Datos No Estructurados

Es la información que carece por completo de una estructura interna predefinida o modelo de datos. Es la categoría que crece más rápidamente en el mundo.

- Características: No se pueden almacenar en tablas ni tienen etiquetas de organización. Para procesarlos se requiere inteligencia artificial, procesamiento de lenguaje natural (NLP) o herramientas de visión por computadora.
- Ejemplos:
 - Archivos multimedia: Videos, imágenes y audios.
 - Documentación de texto libre: PDFs, correos, contratos o libros.
 - Publicaciones de redes sociales (un tuit o post, que incluye texto libre, imágenes y links).

Para almacenar y procesar estas tres estructuras juntas en un solo lugar, las empresas utilizan un Data Lake (Lago de Datos). Las tecnologías como Apache Spark se encargan de leer el desorden de los datos no estructurados y transformarlos en formatos estructurados para poder analizarlos.

Tipo de datos	Características	Ejemplos
Datos Estructurados	Formato rígido con esquema fijo. Se organizan en tablas de filas y columnas. Tipos de datos definidos (números, fechas, texto). Se consultan mediante SQL.	- Tablas de bases de datos relacionales (MySQL, PostgreSQL) - Archivos de hojas de cálculo (Excel, CSV bien formateados)
Datos Semiestructurados	No caben en una tabla tradicional, pero contienen marcadores, etiquetas o jerarquías internas que les dan orden. Esquemas flexibles.	- Archivos JSON (usados en Spring Boot para comunicación front-end) - Archivos XML o HTML (páginas web)
Datos No Estructurados	Carecen por completo de una estructura interna predefinida o modelo de datos. Es la categoría que más crece actualmente.	- Archivos multimedia: videos, imágenes y audios - Documentación de texto libre: PDFs, correos, contratos o libros - Publicaciones de redes sociales (tuits, posts con texto, imágenes y links)

Unstructured data

The university has 5600 students.
 John's ID is number 1, he is 18 years old and already holds a B.Sc. degree.
 David's ID is number 2, he is 31 years old and holds a Ph.D. degree. Robert's ID is number 3, he is 51 years old and also holds the same degree as David, a Ph.D. degree.

Semi-structured data

```
<University>
  <Student ID="1">
    <Name>John</Name>
    <Age>18</Age>
    <Degree>B.Sc.</Degree>
  </Student>
  <Student ID="2">
    <Name>David</Name>
    <Age>31</Age>
    <Degree>Ph.D. </Degree>
  </Student>
  ....
</University>
```

Structured data

ID	Name	Age	Degree
1	John	18	B.Sc.
2	David	31	Ph.D.
3	Robert	51	Ph.D.
4	Rick	26	M.Sc.
5	Michael	19	B.Sc.

Gestión de Datos

Recopilación

Big Data concentra datos de numerosas fuentes y aplicaciones distintas. Los mecanismos de integración de datos convencionales generalmente no están a la altura en dicha tarea. Analizar conjuntos de datos de uno o más terabytes, o incluso petabytes, de tamaño requiere de nuevas estrategias y tecnologías.

Almacenamiento

Una vez que se recopilan los datos, es necesario almacenarlos en algún lugar. Las tres principales soluciones de almacenamiento para Big data son los “Data Lakes”, los almacenes de datos y los LakeHouses de datos.

Data Lakes

-Repositorios que almacena grandes volúmenes de datos en su formato original, sin procesar ni estructurar. Se les da estructura solo cuando se decide usar un conjunto de datos.

Almacenes de datos (Data Warehouse)

-Es una base de datos que estructura los datos, filtra y los optimiza para transformarlos en información útil para el análisis, tanto de la actualidad como del pasado.

Lakehouses de datos

-Es una tecnología híbrida que une un Data Lake y un Warehouse en un solo sistema, almacena grandes volúmenes de datos en bruto y los organiza, limpia y les da estructura a esos datos en tablas para hacer consultas SQL.

	Data Warehouse	Data Lake	Data Lakehouse
¿Qué es?	Almacén de datos organizado y estructurado	Lago de datos en bruto (todo tipo de datos)	Combinación de ambos (Lago + estructura)
Tipo de datos	Solo datos estructurados	Todos los tipos (estructurados, semi y no estructurados)	Todos los tipos (estructurados, semi y no estructurados)
Forma de almacenar	Datos limpios y organizados	Datos en su formato original (crudos)	Datos crudos + capa de organización
Velocidad para guardar	Más lenta (requiere transformación)	Muy rápida	Muy rápida
Uso principal	Reportes y análisis de negocio (BI)	Almacenamiento masivo y experimentación	Análisis avanzado, IA y Machine Learning
Ventaja principal	Datos confiables y fáciles de consultar	Gran flexibilidad y capacidad	Lo mejor de los dos mundos




Diagrama comparativo entre las tres arquitecturas de almacenamiento de datos.

Procesamiento

Luego de almacenar los datos, estos se filtran obteniendo la información más importante. Se realiza de la siguiente manera:

- Se transforma el conjunto de datos a un formato más accesible y eficiente
- Se traducen o cifran para garantizar una mayor seguridad

Análisis

El análisis de Big data es el proceso de examinar los volúmenes masivos de datos para descubrir patrones ocultos, correlaciones, tendencias de mercado y preferencias de los clientes. Este análisis implica el uso de herramientas de machine learning, minería de datos y análisis estadístico.

Con análisis de big data, las empresas pueden aprovechar grandes cantidades de información para descubrir nuevos conocimientos y obtener una ventaja competitiva. Es decir, se pueden mover más allá de los informes tradicionales hacia conocimientos predictivos y prescriptivos.

Tecnologías Relacionadas

Para su funcionamiento completo, big data necesita de tecnologías que trabajen en conjunto para un manejo eficiente de los diferentes tipos de datos.

Hadoop

Hadoop es un framework de código abierto, diseñado para almacenar y procesar los grandes volúmenes de datos de una forma distribuida, eficiente y escalable. Fue desarrollado para resolver los problemas de escalabilidad que presentaban las bases de datos tradicionales al trabajar con cantidades masivas de información. Hadoop divide los datos en múltiples bloques y los distribuye entre distintos servidores, permitiendo procesarlos simultáneamente. Esto mejora considerablemente el rendimiento y reduce costos de infraestructura.

Está compuesto por tres elementos fundamentales para sus funciones:

- HDFS (hadoop distributed file system): es un sistema de almacenamiento, el cual tiene la función de dividir archivos grandes en bloques y almacenarlos en diferentes nodos del sistema. Además, cada bloque se replica varias veces en diferentes servidores para evitar la pérdida de información en caso de que ocurran fallos
- MapReduce: es un modelo de procesamiento que divide las tareas en pequeñas operaciones que funcionan en paralelo en diferentes nodos. Dividiendo este procedimiento en dos etapas
 - Map: procesa y organiza los datos
 - Reduce: combina y resume resultados obtenidos
- YARN(yet another resource negotiator): es el encargado de administrar los recursos del sistema y coordinar las tareas de los diferentes nodos. Mejora el rendimiento

Actualmente, hadoop lo usan empresas tecnológicas en su mayoría por la capacidad de manejar datos de forma distribuida y segura.

```

31 public class STDSubscribers {
32     public static void main(String[] args) throws Exception {
33         Configuration conf = new Configuration();
34         if (args.length != 2) {
35             System.err.println("Usage: stdsubscriber <in> <out>");
36             System.exit(2);
37         }
38         Job job = new Job(conf, "STD Subscribers");
39         job.setJarByClass(STDSubscribers.class);
40         job.setMapperClass(TokenizerMapper.class);
41         job.setCombinerClass(SumReducer.class);
42         job.setReducerClass(SumReducer.class);
43         job.setOutputKeyClass(Text.class);
44         job.setOutputValueClass(LongWritable.class);
45         FileInputFormat.addInputPath(job, new Path(args[0]));
46         FileOutputFormat.setOutputPath(job, new Path(args[1]));
47         System.exit(job.waitForCompletion(true) ? 0 : 1);
48     }

```

Ejemplo de código: Hadoop MapReduce. Esta función recibe un archivo de texto, lo lee y genera claves y valores (setMapperClass) en base a sus contenidos, realiza una reducción de datos (setCombinerClass), y por último combina el resultado en un nuevo archivo (SumReducer).

Apache Spark

Apache spark: Es una plataforma de procesamiento de datos diseñada para trabajar con altos volúmenes de datos de forma rápida y eficiente. A diferencia de hadoop, apache spark hace todo el proceso directamente en la memoria RAM, reduciendo tiempos de procesamiento. Hadoop lo hace directamente en disco

Esta tecnología es utilizada para: análisis en tiempo real, machine learning, inteligencia artificial. También puede integrarse con hadoop y otras herramientas de Big Data como las bases de datos NoSQL y plataformas cloud

Posee diferentes módulos para su funcionamiento:

- SparkSQL: permite realizar consultas parecidas a SQL
- Spark streaming: procesa datos en tiempo real de redes sociales o aplicaciones
- MLlib: es una biblioteca especializada en machine learning

Actualmente, spark es usada por plataformas de streaming u otras como mercado libre o uber, debido a su capacidad de analizar información de manera rápida, generando resultados en tiempo real.

```

1  val df = bucketPeriod
2    .map{date =>
3      val Array(year, month, day) = date.split("-")
4      getAnalytics(BucketRecSysTracking, Brand, year, month, day)
5      .select("c1", "c2", "c3", "c4", "c5", "c6",
6              "c7", "c8", "c9",
7              "c10", "c11", "c12", "c13", "c14", "c15")
8      .filter($"c3".isin(18, 37))
9      .distinct }
10 .filter(_.count > 0)
11 .reduce(_ union _)
12 .cache

```

Ejemplo de código: Apache Spark. Esta función procesa datos históricos por fecha, une toda la información de múltiples días, filtra por una condición específica (columna c3 = 18, 37), elimina duplicados y guarda el resultado en memoria.

HADOOP	SPARK
-Es más lento	-Es más rápido
-Usa disco	-Usa RAM
-MapReduce	-Procesamiento en memoria
-Es bueno para grandes lotes de datos	-Es bueno para obtener respuestas en tiempo real

Machine learning: esta herramienta es más una rama de la inteligencia artificial que les permite a los sistemas aprender automáticamente los datos. Se usa para realizar predicciones a través del análisis de patrones.

Gracias a él, plataformas pueden: recomendar contenido, detectar fraudes, personalizar servicios.

NoSQL

NoSQL es un enfoque utilizado para manejar datos no estructurados en bases de datos relacionales, lo que las convierte en una opción flexible para aplicaciones de Big Data.

En lugar de la típica estructura tabular de una base de datos relacional, las bases de datos NoSQL albergan datos dentro de una estructura de datos, como un documento JSON. Dado que este diseño de base de datos no relacional no requiere un esquema, ofrece una escalabilidad rápida para administrar conjuntos de datos grandes y normalmente no estructurados.

Una empresa de comercio electrónico podría utilizar una base de datos de documentos NoSQL para gestionar y almacenar descripciones de productos, imágenes y reseñas de clientes.

```
> db.user.find().pretty()  
{  
  "_id" : ObjectId("59b19f084597373d365674c0"),  
  "firstname" : "WEI",  
  "lastname" : "Tang",  
  "email" : "weitang0326@gmail.com",  
  "username" : "weitang0326@gmail.com",  
  "password" : "mocha",  
  "__v" : 0  
}
```

Ejemplo de código: NoSQL. Formato de una consulta realizada en MongoDB. La query lanza como resultado un JSON.


	<i>Hadoop</i>	<i>Apache Spark</i>	<i>NoSQL</i>
Objetivo Principal	Almacenamiento y procesamiento de grandes volúmenes de datos	Procesamiento rápido y análisis de datos	Almacenar y consultar datos de forma flexible
Procesamiento	Basado en disco (MapReduce)	En memoria (mucho más rápido)	-
Velocidad	Lento (ideal para lotes grandes)	Muy rápido	Rápido
Tipo de Procesamiento	Principalmente Batch (por lotes)	Batch, Streaming, Machine Learning, SQL	Transaccional (lectura/escritura en tiempo real)
Almacenamiento	Usa HDFS (Distributed File System)	No almacena	Almacena datos directamente (MongoDB)
Uso Ideal	Procesamiento de datos históricos muy grandes	Análisis en tiempo real, Machine Learning, ETL	Aplicaciones web, apps móviles, datos no estructurados
Ventaja Principal	Muy robusto y económico para almacenamiento masivo	Velocidad y versatilidad	Flexibilidad con datos semi y no estructurados
Ejemplos de Uso	Análisis de logs históricos, ETL	Recomendaciones en tiempo real (Netflix, Uber)	Perfiles de usuario, catálogos de productos

Implementaciones

Existe una gran variedad de lenguajes de programación usados para las diferentes tareas del big data, entre ellos podemos destacar Python, por ser uno de los más usados para todo tipo de funciones, otros lenguajes de nuestro interés son Java y SQL por los frameworks contruidos a base de estos.

PROGRAMMING LANGUAGE	Data extraction and manipulation	Statistical analysis and data visualizations	Modeling/ Machine learning	Model deployment	Automation
SQL	✓	✗	✗	✗	✗
PYTHON	✓	✓	✓	✓	✓
R	✓	✓	✓	✗	✓
JAVA	✗	✓	✓	✓	✓
JAVASCRIPT	✗	✓	✓	✓	✗
JULIA	✗	✓	✓	✗	✓
C	✗	✗	✓	✗	✗
C++	✗	✗	✓	✗	✗
C#	✗	✗	✗	✓	✓
TYPESCRIPT	✗	✗	✓	✗	✗
HTML/CSS	✗	✗	✗	✓	✗
PHP	✗	✗	✗	✓	✗
RUST	✗	✗	✗	✓	✗
GOLANG	✗	✗	✗	✓	✗
BASH/SHELL	✗	✗	✗	✗	✓

Diferentes usos de cada lenguaje para big data.



Encuesta hecha en 2021 sobre cuanto se usan diferentes lenguajes de programación para big data.

	Python	Java	SQL
Frameworks	- Apache Spark - Apache Hadoop	- Hadoop - Apache Flink - Apache Beam	- Hadoop - NoSQL - Apache Drill - Apache Hive
Ventajas	- Simple y legible. - Gran cantidad de librerías para el análisis de datos. - Soporte para implementar machine learning e inteligencia artificial. - Integraciones con herramientas para big data.	- Gran escalabilidad y rendimiento. - Independiente de la plataforma de origen, funciona perfectamente entre sistemas. - Muchas librerías y APIs para el entorno de big data. - Gran soporte de la comunidad.	- Familiaridad y facilidad de uso para analistas de datos. - Soporte para consultas complejas y manipulación de datos - Interoperable con otros sistemas de base de datos - Integración con tecnologías de big data a través de Apache Drill y Hive.

Caso Practico: Mercado Libre

Mercado Libre es la plataforma de e-commerce más grande de Latinoamérica. Cada día genera millones de interacciones (búsquedas, clicks, compras, visitas, favoritos, etc.). Todo esto es Big Data.

Características

Característica	Descripción	Tecnologías / Datos utilizados
Volumen	Millones de productos, usuarios y transacciones diarias	Petabytes de datos
Velocidad	Datos en tiempo real (cada click del usuario)	Apache Spark
Variedad	Datos estructurados (compras), semi (JSON), no estructurados (imágenes, comentarios)	Data Lake
Veracidad	Limpieza de datos duplicados o falsos	Procesos de calidad de datos
Valor	Generar recomendaciones y detectar fraudes	Machine Learning

Aplicaciones

Sistema de recomendaciones personalizadas:

Digamos que el usuario realiza una búsqueda de zapatillas “Nike”. ¿Qué más podríamos mostrarle al usuario relacionado a su búsqueda?

- Realizamos un análisis de su historial de compras, favoritos, edad, ubicación, etc.
- Utilizamos algoritmos, como el Machine Learning, para filtrar y obtener contenido relevante.
- Obtenemos como resultado una recomendación personalizada al usuario.

Esto nos trae como beneficio incrementar la probabilidad de realizar una compra por parte del usuario.

Sistema de detección de fraude:

Queremos reducir los intentos de fraude exitosos que suceden dentro de nuestra plataforma. ¿Como podríamos lograrlo?

- Utilizando Apache Spark y Machine Learning, analizamos las transacciones realizadas en tiempo real.
- Comparamos con patrones históricos del usuario (ubicación habitual, dispositivo, monto promedio, hora de compra, etc.).
- Si detectamos comportamiento inusual, bloqueamos la transacción.

Logramos frenar intentos de fraude en la plataforma, incrementando la satisfacción de usuario.

Espacios de Información Nacional

Los espacios de información se refieren a entornos en donde entidades públicas, empresas e individuos pueden participar voluntariamente en la recopilación de datos en temas de interés y uso público. Estos promueven una mayor transparencia entre entidades gubernamentales y la ciudadanía buscando lograr un fácil acceso a información de diversos orígenes.

Portal Nacional de Transparencia

Los **espacios de participación** del **Portal Nacional de Transparencia** ofrecen una variedad de herramientas para el ciudadano, catalogando audiencias públicas, asambleas ciudadanas, consultas públicas y mesas de diálogo. Este portal además ofrece un apartado en donde los ciudadanos se pueden informar sobre su derecho al acceso a información en manos del estado y cómo solicitarla.

Observatorio Nacional de Big Data

Otro de estos espacios colaborativos es el **Observatorio Nacional de Big Data** que busca ser un motor de comunicación en torno a la evolución de las tecnologías de big data en argentina, tratando temas como las posibilidades de innovación, uso público, beneficios tecnológicos, políticos, económicos y sociales, conectando diferentes entidades provinciales y municipales, pymes, emprendedores y micro emprendedores.

Conclusión

El Big Data representa una revolución en la forma de generar, procesar y aprovechar información. Sus características la distinguen de enfoques de almacenamiento y procesamiento de datos tradicionales, y permiten innovaciones que mejoran la eficiencia, personalización y toma de decisiones basándose en evidencia.

El Big Data no es solo “datos grandes”, sino una herramienta estratégica para el progreso con la capacidad de extraer valor a través del análisis avanzado y el aprendizaje automático.

Tabla Resumen

Concepto	Que es	Para que sirve	Ejemplo
Big Data	Conjuntos de datos extremadamente grandes y complejos (estructurados, semiestructurados y no estructurados) que superan las capacidades de las herramientas tradicionales.	Extraer valor, mejorar la toma de decisiones, optimizar procesos y generar conocimiento a partir de grandes volúmenes de información.	Netflix (recomendaciones personalizadas), Mercado Libre (detección de fraudes)
5V	Conjunto de características que definen el Big Data: Volumen, Velocidad, Variedad, Veracidad y Valor.	Ayudar a comprender las particularidades y desafíos del manejo de grandes volúmenes de datos.	Volumen: Petabytes de datos Velocidad: Datos en tiempo real
Data Lake	Repositorio que almacena grandes volúmenes de datos en su formato original (en bruto), sin procesar ni estructurar.	Almacenar datos diversos de forma económica para procesarlos posteriormente según sea necesario.	Almacenar logs, imágenes, videos y datos JSON juntos para análisis futuro
Data Warehouse	Base de datos optimizada que almacena datos estructurados, limpios y organizados.	Realizar análisis históricos y reportes de negocio eficientes.	Reportes financieros mensuales
Lakehouse	Combinación híbrida entre Data Lake y Data Warehouse.	Obtener lo mejor de ambos: flexibilidad + estructura y gobernanza.	Plataformas modernas de análisis avanzado
Hadoop	Framework diseñado para almacenar y procesar grandes volúmenes de datos de forma distribuida y escalable.	Procesar y almacenar datos masivos de manera distribuida en clusters de servidores.	Procesamiento de grandes lotes de datos históricos

Spark	Framework de procesamiento de datos en memoria, mucho más rápida que Hadoop.	Análisis en tiempo real, machine learning, procesamiento de streaming y consultas rápidas.	Análisis de transacciones en tiempo real (Uber, Mercado Libre)
NoSQL	Tipo de bases de datos no relacionales que permiten almacenar datos sin un esquema fijo y con gran flexibilidad.	Manejar datos no estructurados o semiestructurados con alta escalabilidad.	Almacenar descripciones de productos, reseñas e imágenes en una tienda online
Datos Estructurados	Datos con formato rígido, organizados en tablas de filas y columnas con esquema fijo.	Facilitar consultas rápidas y precisas mediante SQL.	Tablas en bases de datos relacionales (MySQL, PostgreSQL), archivos Excel o CSV
Datos Semiestructurados	Datos que no tienen una estructura tabular fija, pero contienen etiquetas o marcadores que les dan cierto orden.	Permitir flexibilidad en el almacenamiento y procesamiento.	Archivos JSON, XML y HTML
Datos no Estructurados	Datos que carecen de una estructura interna predefinida. Es la categoría que más crece.	No se pueden almacenar en tablas ni tienen etiquetas de organización. Para procesarlos se requiere inteligencia artificial, procesamiento de lenguaje natural (NLP) o herramientas de visión por computadora.	Videos, imágenes, audios, PDFs, correos electrónicos, publicaciones en redes sociales

Bibliografía

- IBM. (s.f.). *¿Qué es el big data?* IBM Think. <https://www.ibm.com/es-es/think/topics/big-data>
- IBM. (s.f.). *Apache Hadoop*. IBM Think. <https://www.ibm.com/es-es/think/topics/hadoop>
- IBM. (s.f.). *Apache Spark*. IBM Think. <https://www.ibm.com/mx-es/think/topics/apache-spark>
- IBM. (s.f.). *NoSQL Databases*. IBM Think. <https://www.ibm.com/es-es/think/topics/nosql-databases>
- Oracle. (2024, 23 de septiembre). *¿Qué es el big data?* <https://www.oracle.com/latam/big-data/what-is-big-data/>
- Portal Nacional de Transparencia. (s.f.). *Portal Nacional de Transparencia*. Gobierno de Argentina. <https://portal.transparencia.gob.ar/>
- Rice University. (s.f.). *Programming languages for data science*. <https://csweb.rice.edu/academics/graduate-programs/online-mds/blog/programming-languages-for-data-science>
- The Bridge. (s.f.). *Diferencias entre datos estructurados, no estructurados y semiestructurados*. <https://thebridge.tech/blog/diferencias-entre-datos-estructurados-no-estructurados-y-semiestructurados/>
- **Datatas**. (2014). *The best programming languages for big data*. <https://datatas.com/the-best-programming-languages-for-big-data/>

- **Datos.gob.es.** (2021). *¿Cuándo utilizar cada lenguaje de programación en ciencia de datos?* <https://datos.gob.es/es/blog/cuando-utilizar-cada-lenguaje-de-programacion-en-ciencia-de-datos>
- **Ministerio de Jefatura de Gabinete de ministros.** (s.f.). *Grupo de trabajo de servicios de 5G.* Gobierno de Argentina.
<https://www.argentina.gob.ar/jefatura/innovacion-publica/telecomunicaciones-y-conectividad/grupo-de-trabajo-de-servicios-de-5>